


비즈니스를 위한 데이터마이닝

가톨릭대학교 경영학과

이홍주

나이브 베이즈 Naïve Bayes

- 스팸 메일을 분류하는 모형을 만든다고 가정해 보자.



(출처: <https://medium.com/@naveen.kumar.k/naive-bayes-spam-detection-7d087cc96d9d>)

나이프 베이지 Naïve Bayes

- 총 10개의 메일
- 3개가 스팸 메일
- Free 라는 단어가 포함된 메일은 4개
- 스팸으로 분류된 메일 중 Free 라는 단어를 포함한 메일은 2개
- Free 라는 단어를 포함한 메일이 스팸으로 분류될 확률은?



나이프 베이즈 Naïve Bayes

- 총 10개의 메일

- 3개가 스팸 메일 $P(\text{SPAM}) = \frac{3}{10}$

- Free 라는 단어가 포함된 메일은 4개 $P(\text{Free}) = \frac{4}{10}$

- 스팸으로 분류된 메일 중 Free 라는 단어를 포함한 메일은 2개

$$P(\text{Free} \mid \text{SPAM}) = \frac{2}{3}$$

- Free 라는 단어를 포함한 메일이 스팸으로 분류될 확률은?



$$P(\text{SPAM} \mid \text{Free}) = ?$$



나이브 베이즈 Naïve Bayes

- 베이즈 정리
- 이미 알고 있는 확률 값을 통해서 Free라는 단어가 포함된 메일이 스팸일 확률을 구할 수 있음

- A 라는 사건이 발생할 확률을 $P(A)$ 라고 하면 A 사건과 B 사건이 동시에 일어나는 확률은

$$P(A \cap B) = P(A) \times P(B)$$

- 두 사건이 독립이 아니라면 B라는 사건이 발생하였을 때 A 사건이 발생할 확률은 다음과 같음

$$P(A | B) = \frac{P(A \cap B)}{P(B)}$$

- $P(A)$, $P(B)$, $P(A | B)$ 를 안다면 A라는 사건이 발생하였을 때 B 사건이 발생할 확률 $P(B | A)$ 를 구할 수 있음

나이브 베이즈 Naïve Bayes

- 베이즈 정리

- $P(A | B) = \frac{P(A \cap B)}{P(B)}$, 양변에 $P(B)$ 를 곱하면 다음과 같음

$$P(A | B) \times P(B) = P(A \cap B)$$

- 마찬가지로, $P(B | A) = \frac{P(B \cap A)}{P(A)}$ 양변에 $P(A)$ 를 곱하면 다음과 같음

$$P(B | A) \times P(A) = P(B \cap A)$$

- $P(B \cap A)$ 와 $P(A \cap B)$ 는 동일하므로,

- $P(A | B) \times P(B) = P(B | A) \times P(A)$ 이며, $P(B | A) = \frac{P(A | B) \times P(B)}{P(A)}$

나이브 베이즈 Naïve Bayes

- 총 10개의 메일

- 3개가 스팸 메일 $P(\text{SPAM}) = \frac{3}{10}$

- Free 라는 단어가 포함된 메일은 4개 $P(\text{Free}) = \frac{4}{10}$

- 스팸으로 분류된 메일 중 Free 라는 단어를 포함한 메일은 2개

$$P(\text{Free} \mid \text{SPAM}) = \frac{2}{3}$$

- Free 라는 단어를 포함한 메일이 스팸으로 분류될 확률은?

$$P(\text{SPAM} \mid \text{Free}) = \frac{P(\text{Free} \mid \text{SPAM}) \times P(\text{SPAM})}{P(\text{Free})} = \frac{2/3 \times 3/10}{4/10} = \frac{2}{4}$$

나이브 베이즈 Naïve Bayes

- 모델 중심이 아닌 데이터 중심
- 데이터에 대한 가정을 하지 않음
- 16세기 중반 영국 통계학자이자 장로교 목사인 토마스 베이즈 Thomas Bayes(1702~1761)의 이름을 따서 명명 됨



나이브 베이즈 Naïve Bayes

- 기본 아이디어
 1. 입력 변수 값들이 동일한 다른 모든 레코드를 찾음
 2. 그 레코드들이 어떤 클래스에 속하고 어떤 클래스가 가장 일반적인지 결정
 3. 그 클래스를 새로운 레코드의 답

정확한 베이즈 Exact Bayes

- 입력 변수의 값이 정확히 동일한 다른 데이터 파악
- 해당 입력변수 값일때 어떤 클래스에 속할 확률 계산

$$P(B | A) = \frac{P(A | B) \times P(B)}{P(A)}$$

$$P(C_i | x_1, \dots, x_p) = \frac{P(x_1, \dots, x_p | C_i) P(C_i)}{P(x_1, \dots, x_p | C_1) P(C_1) + \dots + P(x_1, \dots, x_p | C_m) P(C_m)} \quad (8.2)$$

- 입력변수가 많아지면 정확히 일치하는 데이터를 찾기 어려움

나이브 베이즈 Naïve Bayes

- 해결책 - 입력변수들간의 독립 가정
 1. C1 클래스에 대해 각 예측 변수의 개별 조건부 확률 $P(x_j|C_1)$ 추정
 2. 이 확률을 서로 곱한 후 C1 클래스에 속하는 레코드들의 비율을 곱함
- 모든 클래스에 대해서 단계 ①과 ②를 반복한다.
- 클래스 Ci에 대해 단계 ②에서 계산한 값을 모든 클래스의 값들의 합으로 나눠서 클래스 Ci의 확률을 추정한다.

$$P_{nb}(C_1|x_1, \dots, x_p) = \frac{P(C_1)[P(x_1|C_1)P(x_2|C_1) \cdots P(x_p|C_1)]}{P(C_1)[P(x_1|C_1)P(x_2|C_1) \cdots P(x_p|C_1)] + \cdots + P(C_m)[P(x_1|C_m)P(x_2|C_m) \cdots P(x_p|C_m)]} \quad (8.3)$$

예제: 사기 재무 보고 (Financial Fraud)

- 목표 변수: 사기 보고 여부(truthful / fraud)
- 입력 변수
 - 이전 법적 문제 여부 (y / n)
 - 회사 크기 (small / large)

Charges?	Size	Outcome
y	small	truthful
n	small	truthful
n	large	truthful
n	large	truthful
n	small	truthful
n	small	truthful
y	small	fraud
y	large	fraud
n	large	fraud
y	large	fraud

예제: 사기 재무 보고 (Financial Fraud)

- 정확한 베이지
- small / y 인 경우 예측
- 2번 등장. truthful 1번, fraud 1번
- $P(\text{fraud} \mid \text{charges}=y, \text{size}=\text{small})$
 $= \frac{1}{2} = 0.50$

Charges?	Size	Outcome
y	small	truthful
n	small	truthful
n	large	truthful
n	large	truthful
n	small	truthful
n	small	truthful
y	small	fraud
y	large	fraud
n	large	fraud
y	large	fraud

예제: 사기 재무 보고 (Financial Fraud)

- 나이브 베이즈
 - fraud 중 y 비율 * fraud 중 small 비율 * fraud 비율
 $= 3/4 * 1/4 * 4/10 = 0.075$
 - truthful 중 y 비율 * truthful 중 small 비율 * truthful 비율
 $= 1/6 * 4/6 * 6/10 = 0.067$
 - $P(\text{fraud} \mid \text{charges, small}) = 0.075 / (0.075 + 0.067) = 0.528$
- 정확한 베이즈와 큰 확률의 차이는 없음
- 입력변수가 모두 동일한 데이터뿐만 아니라 모든 데이터가 활용됨

나이브 베이즈 Naïve Bayes

알고리즘	주요 데이터 타입	분포 가정	예시	비고
Gaussian	연속형	정규분포	키, 온도, 나이	수치형
Multinomial	이산형(카운트)	다항분포	단어 수	음수 불가
Bernoulli	이진형	베르누이분포	단어 존재 여부	0/1
Categorical	명목형(범주형)	범주 분포	색상, 지역코드	정수 인코딩 필요

예제: 연착 항공편 예측

- 항공기 정시 출발 / 지연 출발 예측
- Flight Status: ontime/delayed

표 8-3 항공편 연착 예제에 대한 변수 설명

Day of week	1=월요일, 2=화요일, ..., 7=일요일
Sch. dep. time	오전 6:00와 오후 10:00 사이를 18개 구간으로 나눈 출발 시간
Origin	3개의 출발 공항 코드: DCA(레이건 국제공항), IAD(덜러스 국제공항), BWI(볼티모어-워싱턴 국제공항)
Destination	3개의 도착 공항 코드: JFK(케네디 국제공항), LGA(라구아디아 공항), EWR(뉴어크 국제공항)
Carrier	8개의 항공사 코드: CO(컨티넨탈 항공), DH(아틀란틱 <u>코스트</u> 항공), DL(델타 항공), MQ(아메리카 이글 항공), OH(컴에어 항공), RU(컨티넨탈 익스프레스 항공), UA(유나이티드 항공), US(US에어웨이 항공)

예제: 연착 항공편 예측

```
delays_df = pd.read_csv('FlightDelays.csv')

# convert to categorical
delays_df.DAY_WEEK = delays_df.DAY_WEEK.astype('category')
delays_df['Flight Status'] = delays_df['Flight
Status'].astype('category')

# create hourly bins departure time
delays_df.CRS_DEP_TIME = [round(t / 100) for t in
delays_df.CRS_DEP_TIME]
delays_df.CRS_DEP_TIME =
delays_df.CRS_DEP_TIME.astype('category')
predictors = ['DAY_WEEK', 'CRS_DEP_TIME', 'ORIGIN', 'DEST',
'CARRIER']
outcome = 'Flight Status'
```

예제: 연착 항공편 예측

Dummies

```
X = pd.get_dummies(delays_df[predictors])  
y = delays_df['Flight Status']  
classes = list(y.cat.categories)
```

split into training and validation

```
X_train, X_valid, y_train, y_valid = train_test_split(X, y,  
                                                    test_size=0.40, random_state=1)
```

Default alpha = 1

run naive Bayes

```
delays_nb = MultinomialNB(alpha=0.01)  
delays_nb.fit(X_train, y_train)
```

Smoothing: 학습 시에 없었던

속성에 대해서 대처

predict probabilities

```
predProb_train = delays_nb.predict_proba(X_train)  
predProb_valid = delays_nb.predict_proba(X_valid)
```

predict class membership

```
y_valid_pred = delays_nb.predict(X_valid)
```

예제: 연착 항공편 예측

$$\begin{aligned}\hat{P}(\text{delayed} | \text{Carrier} = \text{DL}, \text{Day_Week} = 7, \text{Dep_Time} = 10, \text{Dest} = \text{LGA}, \text{Origin} = \text{DCA}) \\ \propto (0.0958)(0.1609)(0.0307)(0.4215)(0.5211)(0.2) = 0.000021\end{aligned}$$

$$\begin{aligned}\hat{P}(\text{ontime} | \text{Carrier} = \text{DL}, \text{Day_Week} = 7, \text{Dep_Time} = 10, \text{Dest} = \text{LGA}, \text{Origin} = \text{DCA}) \\ \propto (0.2040)(0.1048)(0.0519)(0.5779)(0.6478)(0.8) = 0.00033\end{aligned}$$

$$\begin{aligned}\hat{P}(\text{delayed} | \text{Carrier} = \text{DL}, \text{Day_Week} = 7, \text{Dep_Time} = 10, \text{Dest} = \text{LGA}, \text{Origin} = \text{DCA}) \\ = \frac{0.000021}{0.000021 + 0.00033} = 0.058\end{aligned}$$

$$\begin{aligned}\hat{P}(\text{on time} | \text{Carrier} = \text{DL}, \text{Day_Week} = 7, \text{Dep_Time} = 10, \text{Dest} = \text{LGA}, \text{Origin} = \text{DCA}) \\ = \frac{0.00033}{0.000021 + 0.00033} = 0.942\end{aligned}$$

예제: 연착 항공편 예측

표 8-6 예제 항공기의 평가 점수(확률과 클래스)



나이프 베이즈를 사용해 데이터의 점수를 구하는 파이썬 코드

```
# classify a specific flight by searching in the dataset
# for a flight with the same predictor values
df = pd.concat([pd.DataFrame({'actual': y_valid, 'predicted': y_valid_pred}),
                pd.DataFrame(predProb_valid, index=y_valid.index)], axis=1)
mask = ((X_valid.CARRIER_DL == 1) & (X_valid.DAY_WEEK_7 == 1) &
        (X_valid.CRS_DEP_TIME_10 == 1) & (X_valid.DEST_LGA == 1) & (X_valid.ORIGIN_DCA == 1))

df[mask]
```

실행 결과

	actual	predicted	0	1
1225	ontime	ontime	0.057989	0.942011

예제: 연착 항공편 예측

표 8-7 나이브 베이즈 분류기를 사용한 항공편 연착에 대한 혼동 행렬



혼동 행렬을 위한 파이썬 코드

```
# training
classificationSummary(y_train, y_train_pred, class_names=classes)

# validation
classificationSummary(y_valid, y_valid_pred, class_names=classes)
```

실행 결과

Confusion Matrix (Accuracy 0.7955)

Actual	Prediction	
	delayed	ontime
delayed	52	209
ontime	61	998

Confusion Matrix (Accuracy 0.7821)

Actual	Prediction	
	delayed	ontime
delayed	26	141
ontime	51	663